



Trabajo de Fin de Grado

Grado en Ingeniería Informática

Predicción de flujos de tráfico mediante técnicas de Machine Learning

*Prediction of traffic flows using Machine Learning
techniques.*

Javier Ramos Fernández

La Laguna, 30 de marzo de 2018

D. **Jesús Manuel Jorge Santiso**, con N.I.F. 42.097.398-S profesor Titular de Universidad adscrito al Departamento de Ingeniería Informática y de Sistemas de la Universidad de La Laguna, como tutor

C E R T I F I C A

Que la presente memoria titulada:

“Predicción de flujos de tráfico mediante técnicas de Machine Learning”

ha sido realizada bajo su dirección por D. **Javier Ramos Fernández**,
con N.I.F. 45.865.421-V.

Y para que así conste, en cumplimiento de la legislación vigente y a los efectos oportunos firman la presente en La Laguna a 30 de marzo de 2018

Agradecimientos

Gracias a mis padres Jose Luís y Conchi por apoyarme día a día, por el cariño que me han dado, proporcionarme el sustento necesario, ser una fuente de inspiración y soportar mis frustraciones durante el desarrollo de este trabajo.

A mi hermano mayor Eduardo por ser siempre un ejemplo a seguir y por sus consejos de incalculable valor.

A mi hermano mellizo por ser un compañero leal, honesto, trabajador y hacer que el recorrido de mi vida sea un camino lleno de alegrías.

Al resto de mi familia que, a pesar del alejamiento, me hagan pasar unos veranos inolvidables y su apoyo incondicional.

A mis compañeros de clase por proporcionarme ayuda académica constantemente siempre que la he necesitado.

A mi tutor Jesús por haber confiado en mí desde el principio y por la comprensión que ha tenido conmigo en todo momento para llevar a cabo este proyecto.

A mis amigos de toda la vida por ayudarme a evadirme de mis obligaciones y hacerme pasar muy buenos ratos.


A la gente que ha dedicado su tiempo a escuchar mis problemas y me ha animado a seguir adelante.

A todos gracias de corazón. Con paciencia y dedicación se puede conseguir todo lo que te propongas

Javier

Licencia

* Si quiere permitir que se compartan las adaptaciones de tu obra mientras se comparta de la misma manera y quieres permitir usos comerciales de tu obra (licencia de Cultura Libre) indica:



© Esta obra está bajo una licencia de Creative Commons Reconocimiento-CompartirIgual 4.0 Internacional.

Resumen

*El objetivo de este trabajo ha sido realizar predicciones del tiempo promedio de viaje y el volumen de tráfico en la red de carreteras propuesta por la competición KDDCup 2017 (concretamente en **Hangzhou**, provincia de **Zhejiang**, en China). Para llevar a cabo esta tarea, nos hemos basado en la utilización de técnicas de aprendizaje automático para construir modelos de predicción que se adecuen de la forma más precisa posible a los futuros valores reales de tiempo promedio de viaje y volumen de tráfico. De esta forma, se pretende contribuir a la ejecución de medidas preventivas por parte de las autoridades de gestión del tráfico a través de la realización de predicciones fiables para el futuro flujo del tráfico.*

Las herramientas principales utilizadas para desarrollar este proyecto son el sistema de gestión de bases de datos relacional denominado PostgreSQL (para guardar los datos suministrados) y el lenguaje de programación Python (para hacer uso de las librerías que contienen las técnicas de aprendizaje automático, así como otras bibliotecas de utilidad). Mediante la integración de estas dos herramientas, se ha establecido un canal de comunicación entre las diferentes combinaciones de datos creadas y los algoritmos de aprendizaje automático elegidos para llevar a cabo las estimaciones oportunas y realizar evaluaciones de las mismas.

Palabras clave: KDDCup 2017, Aprendizaje Automático, Tráfico carreteras, Tiempo Promedio de Viaje, Volumen de Tráfico, PostgreSQL, Python

Abstract

Here should be the abstract in a foreing language...

Keywords: Keyword1, Keyword2, Keyword3, ...

Índice general

Capítulo 1 Introducción.....	1
1.1 Antecedentes. Problemática y estado del arte.....	2
1.2 Objetivos.....	6
1.3 Organización de la memoria.....	7
Capítulo 2 Tecnologías.....	8
2.1 Almacenamiento de datos.....	8
2.1.1 En el proyecto.....	8
2.1.1.1PostgreSQL.....	8
2.1.2 Otras tecnologías posibles.....	9
2.1.2.1MySQL.....	10
2.1.2.2Oracle.....	11
2.1.2.3Microsoft SQL Server.....	12
2.2 Ciencia de datos.....	13
2.2.1 En el proyecto.....	13
2.2.1.1 Python.....	13
2.2.2 Otras tecnologías posibles.....	14
2.2.2.1 RapidMiner.....	14
2.2.2.2 Lenguaje R.....	15
2.2.2.3 Weka.....	16

Capítulo 3 La minería de datos.....	17
3.1 Primera sección de este capítulo.....	17
3.2 Segundo apartado de este capítulo.....	17
3.3 Tercer apartado de este capítulo.....	17
Capítulo 4 Título del capítulo cuarto.....	18
Capítulo 5 Conclusiones y líneas futuras.....	19
Capítulo 6 Summary and Conclusions.....	20
Capítulo 7 Presupuesto.....	21
7.1 Sección Uno.....	21
Capítulo 8 Título del Apéndice 1.....	22
8.1 Algoritmo XXX.....	22
8.2 Algoritmo YYY.....	22
Capítulo 9 Título del Apéndice 2.....	24
9.1 Otro apéndice: Sección 1.....	24
9.2 Otro apéndice: Sección 2.....	24

Índice de figuras

Figura 2.1: Consola interactiva de PostgreSQL.....	9
Figura 2.2: Entorno gráfico de MySQL Workbench.....	11
Figura 2.3: Entorno gráfico del entorno de desarrollo Oracle JDeveloper.....	12
Figura 2.4: Entorno gráfico de Microsoft SQL Server Management Studio.	13
Figura 2.5: Entorno gráfico de RapidMiner.....	15
Figura 2.6: Entorno gráfico de Weka.....	16

Índice de tablas

Tabla 7.1: Resumen de tipos.....	8
----------------------------------	---

Capítulo 1

Introducción

Cada día generamos una gran cantidad de información, algunas veces conscientes de que lo hacemos y otras veces inconscientes de ello porque lo desconocemos. Nos damos cuenta de que generamos información cuando registramos nuestra entrada en el trabajo, cuando entramos en un servidor para ver nuestro correo, cuando pagamos con una tarjeta de crédito o cuando reservamos un billete de avión. Otras veces no nos damos cuenta de que generamos información, como cuando conducimos por una vía donde están contabilizando el número de automóviles que pasan por minuto, cuando se sigue nuestra navegación por Internet o cuando nos sacan una fotografía del rostro al haber pasado cerca de una oficina gubernamental.

Este aumento exponencial del volumen y variedad de información que se ha presentado en las últimas décadas gracias a la era de la información ha propiciado que se generen grandes volúmenes de conjuntos de datos. El almacenamiento masivo de datos ha generado un interés por analizar, interpretar y extraer información útil de los mismos con el objetivo de obtener conocimiento. Actualmente, los datos son la materia prima para conseguir información provechosa, que se puede utilizar para llevar a cabo una toma de decisiones y la realización de conclusiones. De esta manera, surge el concepto de **minería de datos**, que se define como el proceso de *extraer conocimiento útil y comprensible*, previamente desconocido, desde grandes cantidades de datos almacenados en distintos formatos. Es decir, la tarea fundamental de la misma es encontrar modelos inteligibles a partir de los datos que permitan encontrar aspectos previamente desconocidos de los mismos.

Hoy en día, la minería de datos se considera un campo multidisciplinar que se ha desarrollado en paralelo o como prolongación de otras tecnologías, por lo que la investigación y los avances en la minería de datos se nutren de los que se producen en una serie de áreas relacionadas como las *bases de datos*, la *recuperación de información*, la *visualización de datos*, la *estadística*,

el *aprendizaje automático*, etcétera. De esta manera, este campo de conocimiento es ampliamente utilizado en diversas áreas, que cada vez son más a medida que la tecnología sigue avanzando en este campo y que lo han integrado en su actividad para obtener información de gran valor. Algunas de ellas son el *análisis de datos financieros*, la *industria minorista*, la *industria de las telecomunicaciones*, el *análisis de datos biológicos*, *tráfico*, *educación*, etcétera.

En muchas situaciones, el método tradicional de convertir los datos en conocimiento consiste en un análisis e interpretación realizada de forma manual. El especialista en la materia analiza los datos y elabora un informe o hipótesis que refleja las tendencias o pautas de los mismos. Esta forma de actuar es pausado, costosa y muy subjetiva. En realidad, el análisis manual es impracticable en dominios donde el volumen de los datos crece exponencialmente. Consecuentemente, muchas decisiones importantes se realizan no sobre la base de los datos disponibles, sino siguiendo la propia intuición del usuario al no disponer de las herramientas necesarias. No obstante, actualmente existen herramientas de apoyo, como son las herramientas **OLAP**(*On-line Analytical Processing*, Procesamiento Analítico en Línea), que son técnicas de análisis descriptivo y de sumariaización que permite transformar los datos en otros datos agregados o cruzados de manera sofisticada.

En el caso del trabajo que nos ocupa, la minería de datos es un concepto crucial a emplear en los datos de los que parte el mismo, proporcionados por la competición KDDCup 2017. En este proyecto se pretende utilizar las técnicas y los algoritmos que nos proporciona este área de conocimiento para aplicarlos sobre los datos de tráfico de la competición y obtener previsiones acerca de la tendencia del mismo en una serie de intervalos de tiempo que se nos propone predecir. Así, con la ayuda de dichas estimaciones se puede realizar un control el tráfico a través de la ejecución de decisiones proactivas sobre la red de carreteras (anticiparse al inicio de la congestión del tráfico).

1.1 Antecedentes. Problemática y estado del arte

La realización de predicciones de flujo de tráfico tiene un papel relevante en la sociedad actual debido al gran impacto que tiene el tráfico en la vida diaria de la gente. En muchas ocasiones nos encontramos con un problema

recurrente en las carreteras: la **congestión vehicular**. Actualmente se están realizando una gran cantidad de estudios sobre este tema dada la gran complejidad que presenta puesto que intervienen un considerable número de factores. Las investigaciones que se llevan a cabo en este aspecto son fundamentales para *diseñar las topologías de las carreteras* (intersecciones viales, planes semafóricos, demarcaciones de las vías, señalizaciones verticales, etcétera) de forma óptima y desarrollar *estrategias de planificación* que permitan gestionar de una forma eficaz y eficiente el tráfico; es decir, llevar un control dinámico del mismo que permita realizar y actualizar continuamente *predicciones de los factores* que intervienen en su desarrollo. Esto propiciará un efecto positivo en la economía, el comportamiento de los viajeros, el uso del terreno y otros aspectos.

Algunos ejemplos de estudio en este ámbito son los siguientes:

1. En el artículo [1] se propone utilizar series temporales multivariadas (método de predicción multivariante) para pronosticar variables de tráfico. Este método se plantea frente a las series temporales escalares que, aunque en teoría son genéricamente suficientes para reconstruir la dinámica de los sistemas subyacentes, resulta más enriquecedor utilizar todas las variables disponibles.
2. En el artículo [2] se estudia la cuestión acerca del tiempo de validez en que se mantiene eficaz una serie histórica de tiempos de flujo del tráfico para predecir el futuro. Es decir, se plantea el tiempo t que puede perdurar la eficacia de los datos de flujo de tráfico existentes en un tiempo t_0 para estimar tendencias de variación del flujo de tráfico en un tiempo t_0+t . Para ello, recopilan los datos de las series temporales de flujo de tráfico con diferentes granularidades y realizan una serie de análisis y métodos como analizar la propiedad de memoria larga de las series temporales del flujo de tráfico mediante el cálculo del exponente Hurst, además de un conjunto de comparaciones.
3. El artículo [3] es un Trabajo de Fin de Grado en el que se trata el tema de la predicción del tráfico en las carreteras de la red de la Generalitat Valenciana. El autor pretendía con este trabajo la posibilidad de mejorar la metodología empleada en algunas fases de la explotación de los datos de aforos a través del uso de métodos científicos, complementándola con herramientas estadísticas. Esto se hace puesto que los planes de aforo no pueden obtener el muestreo completo de toda la red durante todo el año dado el alto número de puntos de toma de datos y los recursos necesarios para abarcarlos todos de forma permanente. Para realizar la mejora, el autor considera la Intensidad Media Diaria (IMD) como la variable más importante a calcular en un

Plan de Aforos. Para poder llevar a cabo el cálculo de dicha variable, define los tramos sobre la red de carreteras (además de realizar estudios de retramificación para valorar los cambios en la red y adaptar los tramos definidos a la realidad viaria conforme ésta va evolucionando). A continuación, realiza un diseño de muestreo (de cada uno de los tramos de aforo con el objetivo de obtener muestras lo suficientemente representativas como para caracterizar el tráfico en cada tramo, de forma que la asignación de recursos sea óptima) y, a partir de esto, se diseña el plan de distribución de muestreo de estaciones (diversos tipos de estación según la frecuencia de muestreo de los mismos), asignando cada una de ellas a una tipología. Para llevar a cabo esto último se tienen en cuenta los recursos materiales y humanos de los que se dispone para poder cumplir con el muestreo del plan anual de aforos resultante de dichas asignaciones.

4. En el artículo [4] se estudian las tendencias de movilidad urbana en París, Santiago de Chile, Singapur y Viena con el objetivo de analizar la demanda de las diversas formas de transporte que existen en esas ciudades y establecer políticas adecuadas. No solo se examinan estas tendencias, sino también sus causas. Para ello, primero se identifican las tendencias específicas de cada una de las ciudades principalmente a través de indicadores de transporte, como los datos de viaje con respecto a los usuarios y estructuras espaciales, además de analizar el contexto de cada ciudad (infraestructura, desarrollo económico y desarrollo social de la ciudad) y realizar un modelo para explicar el comportamiento de los usuarios frente a unas tendencias u otras a partir de la diferenciación entre los motivos socio-emocionales y racionales de los mismos. A continuación, se consultan a expertos en el sistema de transporte de cada una de las ciudades para validar esas tendencias identificadas y preparar análisis cualitativos. Por último, se realizan análisis para comprender y describir las tendencias desde la perspectiva de los viajeros. El artículo examina una amplia gama de modos de transportes espacialmente y socialmente diferenciados.
5. El tema del artículo [5] consiste en realizar estimaciones a corto plazo (15 minutos en el futuro) con la información histórica del tráfico de la red de autopistas del Reino Unido utilizando redes neuronales, de tal forma que esto permita reducir la congestión del transporte mediante la mejora de sistemas inteligentes de transporte utilizados para controlar el tráfico para que realicen decisiones proactivas sobre la red de carreteras (anticiparse al inicio de la congestión del tráfico). Se plantean efectuar estas decisiones anticipadas a través de advertencias de la congestión esperada, lo que permitiría a los controladores disponer de más tiempo

para evaluar las diferentes estrategias de mitigación, en lugar de una vez que se materialice la congestión. También se propone que las predicciones se hagan visibles al público, de manera que el sistema de transporte se pueda beneficiar ya que permitiría a los usuarios optimizar sus planes de viaje, ya sea redirigiendo o reprogramando el itinerario de su viaje.

Además de los artículos anteriormente mencionados, la competición KDDCup 2017 tiene publicadas las presentaciones de los ganadores de la misma. A continuación se exponen dichos documentos:

1. El documento [6] presenta los resultados del equipo que acabó en el primer puesto de predicción del tiempo promedio de viaje. Para realizar las predicciones, se basaron en unos cuantos modelos de aprendizaje automático como XGBoost, LightGBM y Multilayer Perceptron y se sirven de técnicas combinadas de aprendizaje basadas en funciones de pérdidas, transformaciones de logaritmos y otros métodos.
2. El documento [7] presenta los resultados del equipo que acabó en el segundo puesto de predicción del tiempo promedio de viaje. Se basa principalmente en utilizar XGBoost para realizar las estimaciones de tiempo promedio de viaje, haciendo hincapié en cómo resolver la falta de datos en los conjuntos de datos proporcionados por la competición.
3. El documento [8] presenta los resultados del equipo que acabó en el tercer puesto de predicción del tiempo promedio de viaje. En este trabajo se sigue un adecuado orden de ejecución de fases para realizar las predicciones, desde el preprocesado de datos hasta la realización de métodos combinados de aprendizaje, pasando por la extracción de características y el análisis y elección de modelos de predicción. Aparte de utilizar XGBoost para realizar las predicciones, utilizan el modelo ARIMA, que es muy utilizado para la predicción de series temporales.
4. El documento [9] presenta los resultados del equipo que acabó en el primer puesto de predicción del volumen de tráfico. Este equipo es el mismo que quedó en el primer puesto en la tarea de predicción del tiempo promedio de viaje. Los modelos que utilizan son prácticamente los mismo que utilizaron para estimar el tiempo promedio de viaje, y prestaron gran atención a las características estadísticas de los datos.
5. El documento [10] presenta los resultados del equipo que acabó en el segundo puesto de predicción del volumen de tráfico. En este trabajo se realizaron pruebas sobre muchos modelos de predicción, entre los que se incluyen algunos mencionados en los trabajos anteriores y el modelo KNN (k-Nearest Neighbours).

6. El documento [11] presenta los resultados del equipo que acabó en el tercer puesto de predicción del volumen de tráfico. El aspecto más relevante de este trabajo es que el autor realiza las predicciones con un sólo modelo, que es la regresión lineal. Para que este modelo pudiera dar buenos resultados, se hizo hincapié en la eliminación de ruido sobre los datos.

Para poder desarrollar este trabajo de predicción de flujos de tráfico, se ha considerado utilizar los datos proporcionados por la competición denominada **KDDCup**, concretamente la edición del año 2017. Esta competición es una competición anual de *Minería de Datos y Descubrimiento de Conocimiento* organizada por **SIGKDD (Association for Computing Machinery's Special Interest Group on Knowledge Discovery and Data Mining)**, la organización profesional líder de minería de datos. En dicha competición se plantea una problemática, se proporcionan los datos necesarios para solventarla y se premian las mejores soluciones propuestas.

El tema elegido por la organización de la KDD Cup 2017 para este año estaba directamente relacionado con la predicción de los flujos de tráfico de las autopistas de peaje en China (concretamente en **Hangzhou**, provincia de **Zhejiang**). El objetivo final era ofrecer a los responsables de la gestión del tráfico medidas preventivas basadas en datos y preparar el camino hacia una solución holística y realista a los cuellos de botella del tráfico.

1.2 Objetivos

Los objetivos contemplados a completar en el desarrollo de este proyecto son los siguientes:

- *Creación de una serie de bases de datos para almacenar los datos proporcionados por la competición.* Con el objetivo de poder acceder fácilmente y de forma flexible a la información suministrada por la competición KDDCup 2017, se ha planteado crear un conjunto de bases de datos que permita ordenar y clasificar los datos, de tal forma que se tenga una comprensión más acertada de ellos, se puedan realizar distintas combinaciones sobre los mismos y se genere nuevo conocimiento para llevar a cabo estimaciones.

- *Realización de varias aproximaciones de predicciones del tiempo promedio de viaje.* Tras llevar a cabo la preparación preliminar de los datos a utilizar, se propone llevar a cabo diversas aproximaciones para predecir el tiempo promedio de viaje en las rutas y los intervalos de tiempo requeridos por la competición.
- *Realización de varias aproximaciones de predicciones del volumen de tráfico.* De igual manera que el tiempo promedio de viaje, también se procede a construir aproximaciones de predicciones del volumen de tráfico en las distintas barreras de peaje y en los intervalos solicitados por la competición.

1.3 Organización de la memoria

La disposición de la información que se va a seguir para abarcar todo lo relacionado con el desarrollo y ejecución del proyecto es la siguiente:

- En el capítulo 2 se introducen las tecnologías utilizadas para llevar a cabo la carga de las bases de datos que almacenan los datos de la competición y la aplicación de diferentes modelos de predicción sobre los mismos.
- En el capítulo 3 se explican las nociones fundamentales de la minería de datos, así como la descripción de distintas técnicas de aprendizaje automático empleadas para descubrir patrones y tendencias que existen en nuestros datos.
- En el capítulo 4 se abordan de forma detallada las distintas fases del proyecto, desde la creación de las bases de datos hasta la redacción de documentación.

Capítulo 2

Tecnologías

La elección de las herramientas y tecnologías empleadas para el desarrollo del proyecto se ha realizado cautelosamente, de tal forma que nos ha permitido concentrarnos en el problema en cuestión en lugar de tener que instruirnos exhaustivamente en ellas y que aumentara la complejidad del trabajo. A continuación, se enumeran las principales tareas del proyecto junto con el software al que se ha recurrido para completarlas.

2.1 Almacenamiento de datos

2.1.1 En el proyecto

2.1.1.1 PostgreSQL

PostgreSQL es un potente sistema de base de datos objeto-relacional de código abierto basado en el paquete POSTGRES, desarrollado en el Departamento de Informática de la Universidad de California en Berkeley y liberado bajo la licencia BSD. Es un sistema que permite la creación, gestión y administración de bases de datos, así como la elección y manejo de las estructuras necesarias para el almacenamiento y búsqueda de la información del modo más eficiente posible. Como muchos otros proyectos de código abierto, el desarrollo de PostgreSQL no es manejado por una sola compañía, sino que es dirigido por una comunidad de desarrolladores y organizaciones comerciales las cuales trabajan en su desarrollo; dicha comunidad es denominada el *PGDG (PostgreSQL Global Development Group)*.

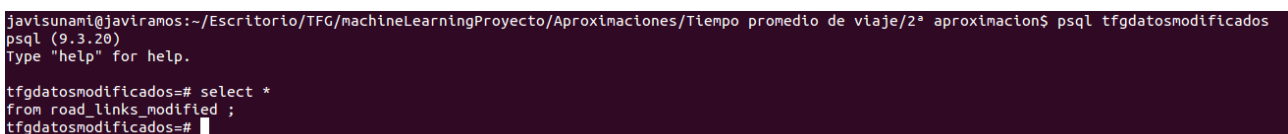
Este sistema de base de datos soporta una gran parte del estándar SQL y ofrece muchas características modernas incluyendo las siguientes:

- Consultas SQL complejas

- Sub-selecciones SQL
- Claves externas
- Disparadores
- Vistas actualizables
- Transacciones
- Control de concurrencia multi-versión (MVCC)
- Integridad transaccional
- Replicación de Streaming (a partir de 9.0)
- Espera en caliente (a partir de 9.0)
- Etc.

Además, PostgreSQL puede ser ampliado por el usuario de muchas maneras, por ejemplo, añadiendo nuevo

- tipos de datos
- funciones
- operadores
- funciones agregadas
- métodos de indexación
- lenguajes procedimentales



```
javisunamijaviramos:~/Escritorio/TFG/machineLearningProyecto/Aproximaciones/Tiempo promedio de viaje/2ª aproximacion$ psql tfgdatosmodificados
psql (9.3.20)
Type "help" for help.

tfgdatosmodificados=# select *
from road_links_modified ;
tfgdatosmodificados=#
```

Figura 2.1: Consola interactiva de PostgreSQL

2.1.2 Otras tecnologías posibles

Existen multitud de herramientas, aparte de la mencionada anteriormente, para almacenar los datos sistemáticamente para su posterior uso. A continuación se mencionan algunas destacadas.

2.1.2.1 *MySQL*

MySQL es un sistema de administración de bases de datos relacional. Se trata de un programa capaz de almacenar una enorme cantidad de datos de gran variedad y de distribuirlos para cubrir las necesidades de cualquier tipo de organización, desde pequeños establecimientos comerciales a grandes empresas y organismos administrativos. Este sistema incluye todos los elementos necesarios para instalar el programa, preparar diferentes niveles de acceso de usuario, administrar el sistema y proteger y hacer volcados de datos. Puede desarrollar sus propias aplicaciones de base de datos en la mayor parte de los lenguajes de programación utilizados en la actualidad y ejecutarlos en casi todos los sistemas operativos. Además, utiliza el *lenguaje de consulta estructurado* (SQL). Se trata del lenguaje utilizado por todas las bases de datos relacionales.

Comparado con *PostgreSQL*, este sistema de administración de bases de datos se ha enfocado tradicionalmente en aplicaciones web de lectura mayormente, usualmente escritas en PHP, donde la principal preocupación es la optimización de consultas sencillas. En cambio, *PostgreSQL* se ha enfocado tradicionalmente en la fiabilidad, integridad de datos y características integradas enfocadas al desarrollador. Tiene un planificador de consultas extremadamente sofisticado, que es capaz de unir cantidades relativamente grandes de tablas eficientemente.




Figura 2.2: Entorno gráfico de MySQL Workbench

2.1.2.2 Oracle

Oracle Database es un sistema de gestión de bases de datos de tipo objeto-relacional desarrollado por *Oracle Corporation*. Se considera como uno de los sistemas de bases de datos mas completos, destacando el *sopore de transacciones*, la *estabilidad*, la *escalabilidad* y el *soporte multiplataforma*. No obstante, la gran potencia que tiene y su elevado precio hace que solo se utilice en empresas muy grandes y multinacionales, por norma general.

La diferencia principal entre *Oracle* y *PostgreSQL* es el hecho de que el primero no es software de código abierto, mientras que el segundo si. Por otra parte, *PostgreSQL* hace más sencillo el análisis de datos y tiene una mayor seguridad, pero *Oracle* si soporta consultas en paralelo.

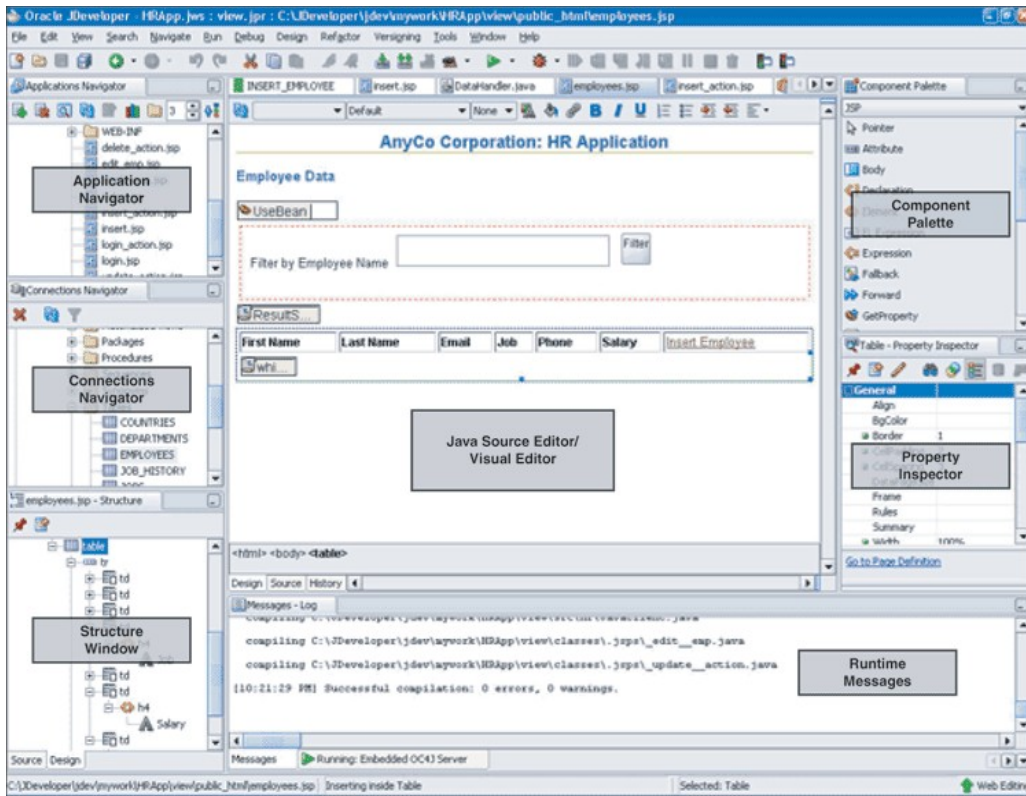


Figura 2.3: Entorno gráfico del entorno de desarrollo Oracle JDeveloper

2.1.2.3 Microsoft SQL Server

Microsoft SQL Server es un sistema de gestión de base de datos relacional (RDBMS) producido por Microsoft. Su principal lenguaje de consulta es *Transact-SQL*, una aplicación de las normas ANSI / ISO estándar Structured Query Language (SQL). Las características principales de este sistema son las siguientes:

- Soporte de transacciones.
- Escalabilidad, estabilidad y seguridad.
- Soporta procedimientos almacenados.
- Incluye también un potente entorno gráfico de administración, que permite el uso de comandos DDL y DML gráficamente.
- Permite trabajar en modo cliente-servidor, donde la información y los datos se alojan en el servidor y las terminales o clientes de la red acceden a la información.
- Permite administrar información de otros servidores de datos.

Una de las diferencias principales de *PostgreSQL* con respecto a *Microsoft SQL Server* es que es **multiplataforma**; el primero puede ejecutarse en Linux, BSD y Windows, pero el segundo solo se puede ejecutar en Windows. Además, el primero posee una facilidad de uso mayor que el segundo. No obstante, *PostgreSQL* es más lento que *Microsoft SQL Server*.




Figura 2.4: Entorno gráfico de Microsoft SQL Server Management Studio

2.2 Ciencia de datos

2.2.1 En el proyecto

2.2.1.1 *Python*

Python es un lenguaje de programación interpretado cuya filosofía hace hincapié en una sintaxis que favorezca un código legible. Se trata de un lenguaje de programación *multiparadigma*, ya que soporta orientación a objetos, programación imperativa y, en menor medida, programación funcional. Aparte de esto, es un lenguaje *dinámico* y *multiplataforma*, muy adecuado para el desarrollo interactivo y la creación rápida de prototipos con la capacidad de soportar el desarrollo de grandes aplicaciones. También es

ampliamente utilizado para el *aprendizaje automático* y la *ciencia de datos* debido al excelente soporte de bibliotecas y a que es un lenguaje de programación de propósito general.

Este lenguaje tiene a su disposición un ecosistema de bibliotecas en Python para matemáticas, ciencias e ingeniería denominado **SciPy**. Es un complemento de Python necesario para el aprendizaje automático y está compuesto por los siguientes módulos básicos relevantes:

- **NumPy**: Un módulo para SciPy que permite trabajar eficientemente con datos en vectores y matrices.
- **Matplotlib**: Una biblioteca que permite crear gráficos en 2D y gráficos a partir de datos.
- **Pandas**: Una biblioteca que contiene herramientas y estructuras de datos para organizar y analizar datos.

Por otra parte, la biblioteca fundamental para desarrollar y realizar aprendizaje automático en Python se denomina **scikit-learn**. Se basa en el ecosistema de SciPy y lo requiere. El núcleo de la biblioteca son los algoritmos de aprendizaje automático para clasificación, regresión, agrupamiento y más, y también proporciona herramientas para tareas relacionadas tales como la *evaluación de modelos*, *ajuste de parámetros* y *preprocesamiento de datos*. Al igual que Python y SciPy, **scikit-learn** es de código abierto y es utilizable comercialmente bajo la licencia BSD.

2.2.2 Otras tecnologías posibles

Existen muchas más herramientas, aparte de la mencionada anteriormente, para poner en práctica el aprendizaje automático. A continuación se nombran algunas de las más importantes.

2.2.2.1 *RapidMiner*

RapidMiner es un programa informático para el análisis y la minería de datos. Permite el desarrollo de procesos de análisis de datos mediante el encadenamiento de operadores a través de un entorno gráfico. Se usa en investigación, educación, capacitación, creación rápida de prototipos y en aplicaciones empresariales. Las características principales de este software es que está *desarrollado en Java*, es *multiplataforma*, utiliza archivos XML para la *representación interna de los procesos de análisis de datos*, permite el

desarrollo de programas a través de un lenguaje script, puede usarse de diversas maneras (a través de GUI, en línea de comandos, en lotes y desde otros programas a través de llamadas a sus bibliotecas), es *extensible*, incluye gráficos y herramientas de *visualización de datos* y dispone de un *módulo de integración con el lenguaje R*.

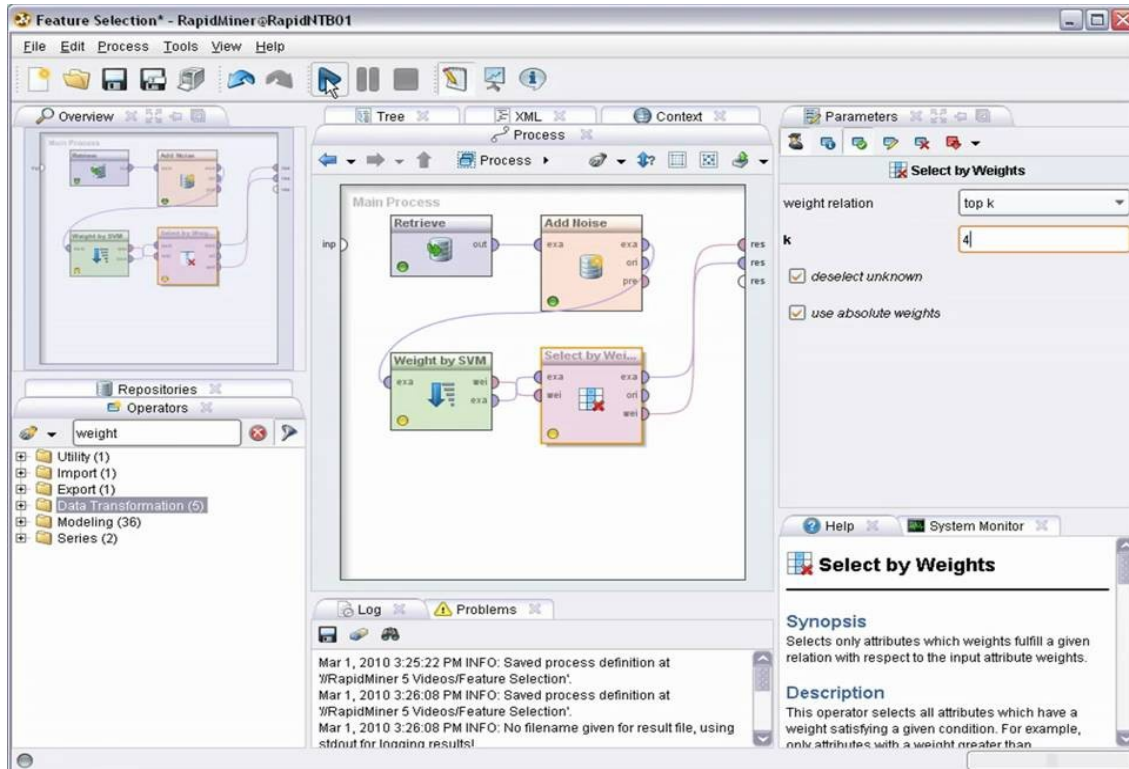


Figura 2.5: Entorno gráfico de RapidMiner

2.2.2.2 Lenguaje R

R es un entorno y un lenguaje de programación enfocado en el **análisis estadístico** de los más utilizados en el campo de la minería de datos que pueden aplicarse a gran variedad de disciplinas. Este lenguaje es un *proyecto colaborativo y abierto*, por lo que los desarrolladores pueden descargar el código de forma gratuita y modificarlo para incluir mejoras. Por otra parte, es un *lenguaje interpretado*, funciona mediante comandos, proporciona una *amplia gama de herramientas estadísticas* que incluyen análisis de datos y generación de gráficos de alta calidad. Gracias a este lenguaje de programación los ingenieros de datos pueden *manejar grandes volúmenes de datos*.

Python, con respecto a *R*, es un lenguaje de propósito general con una sintaxis fácil de entender y con una curva de aprendizaje muy corta. En cambio la funcionalidad de *R* se desarrolla pensando en los estadísticos, lo que le da ventajas específicas de campo tales como importantes características para la visualización de datos, pero es más difícil de aprender.

2.2.2.3 Weka

Weka es un software libre y de código abierto basado en Java, licenciado bajo la GPL de GNU y disponible para su uso en Linux, Mac OS X y Windows. Comprende una colección de *algoritmos de aprendizaje automático* para minería de datos y empaqueta *herramientas de preprocesamiento, clasificación, regresión, clustering, reglas de asociación y visualización de datos*. Además, tiene una interfaz gráfica fácil de usar para la visualización bidimensional de datos minados, permite importar los datos sin procesar desde varios formatos de archivo y soporta algoritmos bien conocidos para diferentes acciones de minería de datos como *filtrado, agrupación, clasificación y selección de atributos*. Este software también proporciona un *Java Appletiser* para su uso en aplicaciones y puede conectarse a bases de datos utilizando *CJD*.

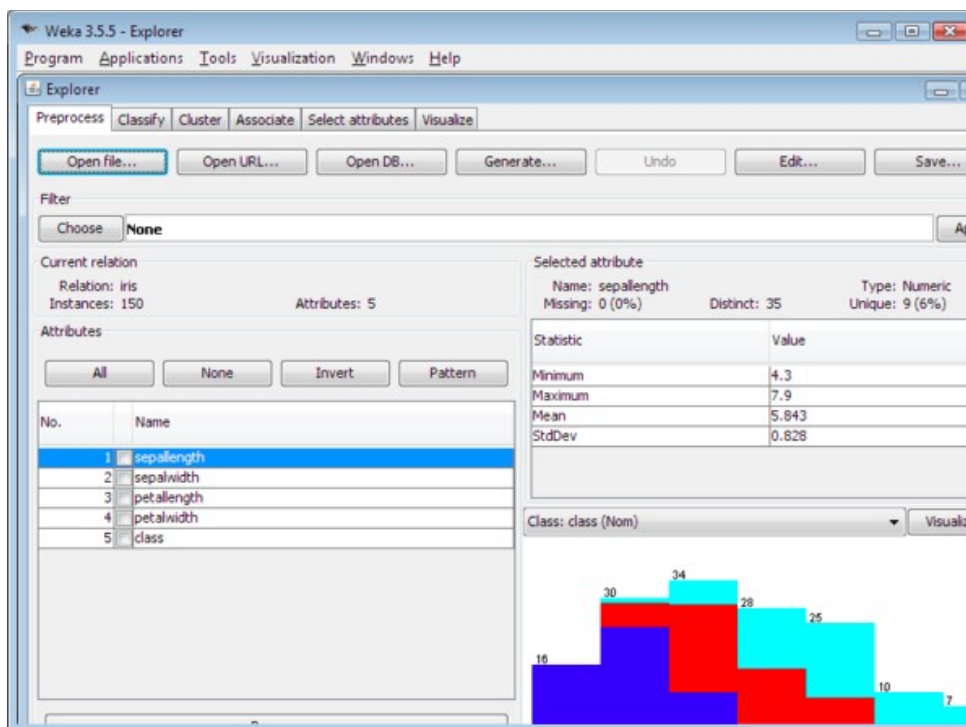


Figura 2.6: Entorno gráfico de Weka

Capítulo 3

La minería de datos

3.1 Introducción

La **minería de datos** es el proceso de descubrir automáticamente información útil en grandes repositorios de datos. Las técnicas de minería de datos se utilizan para rastrear grandes bases de datos con el fin de encontrar patrones novedosos y útiles que, de otro modo, podrían seguir siendo desconocidos. También proporcionan capacidades para predecir el resultado de una observación futura, como predecir el tiempo meteorológico o, en relación a este trabajo, características de tráfico.

La minería de datos es una parte integral del *descubrimiento de conocimiento en bases de datos* (**KDD, Knowledge Discovery in Databases**), que es el proceso general de conversión de datos brutos en información útil, como se muestra en la Figura 3.1. Este proceso consiste en una serie de pasos de transformación, desde el preprocesamiento de datos hasta el postprocesamiento de los resultados de la minería de datos.

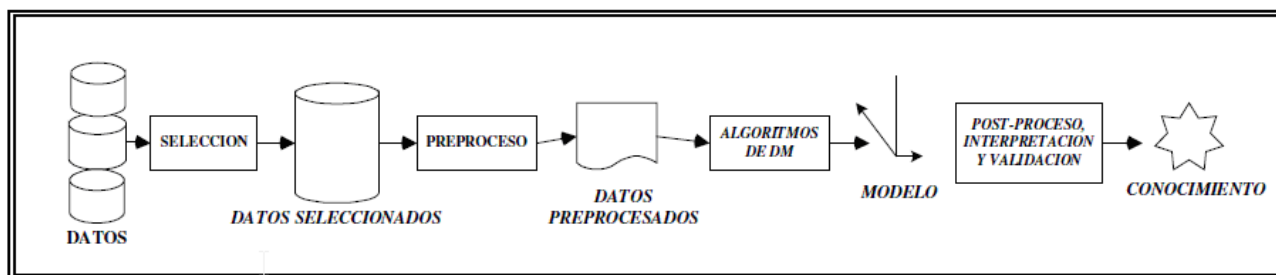


Figura 3.1: El proceso de descubrimiento de conocimiento en bases de datos (KDD)

- Los **datos de entrada** pueden almacenarse en una variedad de formatos (archivos planos, hojas de cálculo o tablas relacionales) y pueden residir en un repositorio de datos centralizado o distribuirse en varios sitios.
- El propósito del **preprocesamiento** es *transformar los datos* de entrada brutos en un formato apropiado para el análisis posterior. Los pasos involucrados en el preprocesamiento de datos incluyen la fusión de datos de múltiples fuentes, la limpieza de datos para eliminar el ruido y la duplicación de observaciones, y la selección de registros y características que son relevantes para la tarea de minería de datos a mano. Debido a las muchas maneras en que los datos pueden ser recolectados y almacenados, el *preprocesamiento* de datos es quizás el paso más laborioso y que consume más tiempo en el proceso general de descubrimiento de conocimiento.
- El objetivo del siguiente proceso es **integrar los resultados de la minería de datos** en los sistemas de apoyo a la toma de decisiones. Es la **fase de modelamiento** propiamente tal, en donde métodos inteligentes son aplicados con el objetivo de extraer patrones previamente desconocidos, válidos, nuevos, potencialmente útiles y comprensibles y que están contenidos u “ocultos” en los datos.
- La fase anterior (de integración de resultados) requiere una etapa de **tratamiento posterior** que garantice que en el sistema de apoyo a la adopción de decisiones sólo se incorporen resultados válidos y útiles. Es decir, se **identifican los patrones obtenidos** y que son realmente interesantes, basándose en algunas medidas y se realiza una **evaluación de los resultados obtenidos**.

3.2 Primera sección de este capítulo

3.3 Segundo apartado de este capítulo

3.4 Tercer apartado de este capítulo

Capítulo 4

Título del capítulo cuarto

Los capítulos intermedios servirán para cubrir los siguientes aspectos: antecedentes, problemática o estado del arte, objetivos, fases y desarrollo del proyecto.

El el capítulo 1 se describió bla, bla, bla ...

Capítulo 5

Conclusiones y líneas futuras

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir unas conclusiones y unas líneas de trabajo futuro

Capítulo 6

Summary and Conclusions

This chapter is compulsory. The memory should include an extended summary and conclusions in english.

Capítulo 7

Presupuesto

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir un presupuesto.

7.1 Sección Uno

Tipos	Descripción
AAAA	BBBB
CCCC	DDDD
EEEE	FFFF
GGGG	HHHH

Tabla 7.1: Resumen de tipos

Capítulo 8

Título del Apéndice 1

8.1 Algoritmo XXX

```
/******  
*  
* Fichero .h  
*  
*****  
*  
* AUTORES  
*  
*  
* FECHA  
*  
*  
* DESCRIPCION  
*  
*  
*****/
```

8.2 Algoritmo YYY

```
/******  
*  
* Fichero .h  
*  
*****  
*  
*****/
```

* AUTORES

*

* FECHA

*

* DESCRIPCION

*

*

*****/

- *Modificación de las bases de datos creadas para adecuarlas a las tareas de predicción.* Una vez realizada la carga de las bases de datos, se propone modificar los esquemas de las tablas que componen dichos almacenes de datos para que la información contenida en ellos sea lo más manejable posible. En este aspecto, nos centramos en la modificación de los tipos de datos de los atributos de las distintas tablas de las bases de datos.
1. *Creación de gráficas para visualizar los datos almacenados.* Con el fin de visualizar la información contenida en los datos suministrados y tener una comprensión global de la misma, se pretende desarrollar una serie de gráficas que nos permitan conocer las características de los datos y poder abordar las predicciones a realizar de la mejor forma posible.

Capítulo 9

Título del Apéndice 2

9.1 Otro apéndice: Sección 1

texto

9.2 Otro apéndice: Sección 2

texto

Bibliografía

- [1] Y. Yin and P. Shang. “Forecasting traffic time series with multivariate predicting method”. *Applied Mathematics and Computation* vol 291, pp. 266-278, 2016. [Online]. Disponible en: <https://goo.gl/5gkEfp>
- [2] P. Yuan and X. Lin. “How long will the traffic flow time series keep efficacious to forecast the future?”. *Physica A: Statistical Mechanics and its Applications* vol 467, pp. 419-431, 2017. [Online]. Disponible en: https://drive.google.com/open?id=1r4ZF2wughH4nZcRUsQqqn_hmrSSR6mw8
- [3] H. A. Sevilla, "Predicción de tráfico en las carreteras de la red de la Generalitat Valenciana", Trabajo fin de carrera, Dep. De Sistemas Informáticos y Computación, Escola Tècnica Superior d'Enginyeria Informàtica, Universitat Politècnica de València, Valencia, 2015. [Online]. Disponible en: <https://drive.google.com/open?id=1usrXMdc7c-J3-1Rt2CjzAHLvZII3eeEO>
- [4] M. Goletz, I. Feige and D. Heinrichs. “What Drives Mobility Trends: Results from Case Studies in Paris, Santiago de Chile, Singapore and Vienna,”. *Transportation Research Procedia* vol 13, pp. 49-60, 2016. [Online]. Disponible en: <https://drive.google.com/open?id=1590qIrBgZvJjANFsTvHYZILkWRz9vfFN>
- [5] C. Gloves, R. North, R. Johnston and G. Fletcher. “Short Term Traffic Prediction on the UK Motorway Network Using Neural Networks”. *Transportation Research Procedia* vol 13, pp. 184-195, 2016. [Online]. Disponible en: https://drive.google.com/open?id=1rDz5GfONXSf7ZFhLcgQv_FFfSnrmj55F

- [6] K. Hu, P. Huang, H. Chen and P. Yan, “KDD CUP 2017 Travel Time Prediction Predicting Travel Time – The Winning Solution of KDD Cup 2017”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: https://drive.google.com/open?id=12a4pBbxA6h_zy517ARtHTtn61w7uZ7jJ
- [7] Y. Huang, “Highway Tollgates Traffic Flow Prediction Task 1. Travel Time Prediction”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: https://drive.google.com/open?id=1GD1ZIpWDq7qMM7bvpTSTnIWqSnpDlS_t
- [8] H. Cai, R. Zhong, C.Wang et al., “KDD CUP 2017 Travel Time Prediction”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: <https://drive.google.com/open?id=1ew6oLOPHGoz8IMIt5g6XkZn67ADDtxJJ>
- [9] K. Hu, P. Huang, H. Chen and P. Yan, “KDDCUP 2017 Volume Prediction Step by step modeling for travel volume prediction”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: <https://drive.google.com/open?id=1uK8IwRTe061NVbWQn4FQFxFH7BUx6b6mq>
- [10] J. Zhou, Y. Guo, Y. Chen, J. Lin and H. Lin, “Learning and Prediction over Light-Weight Spatio-Temporal Data”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: https://drive.google.com/open?di=1Jbz0GNxYcjCghp0cfJia0omYKu1y5_aR
- [11] S. Luo, “KDD CUP 2017: Volume Prediction Task Solution”, presented at the KDD 2017, Halifax, Nova Scotia – Canada, 2017. [Online]. Disponible en: <https://drive.google.com/open?id=1-krIjoSatfoPNnzYRSOZKfxIKK0RHT59>

<http://www.it.uc3m.es/jvillena/irc/practicas/06-07/22.pdf>

<https://blog.es.logicalis.com/analytics/mineria-de-datos-aplicaciones-que-ya-son-una-realidad>

<http://www.it.uc3m.es/jvillena/irc/practicas/10-11/15mem.pdf>

http://sedici.unlp.edu.ar/bitstream/handle/10915/35555/Documento_completo.pdf?sequence=1